

Retail Customer Behavior Analysis & Churn Prediction

Pipeline Machine Learning complet — SVM, PCA, Feature Engineering

"Savez-vous combien coûte réellement la perte d'un client fidèle par rapport à l'acquisition d'un nouveau ?"

Auteur : Ines KETATA Date : Avril 2026



TABLE DES MATIÈRES

Retail Customer Behavior Analysis & Churn Prediction




1. Contexte & Problématique

Enjeux stratégiques de la rétention client dans le secteur retail.



2. Dataset & Données

Exploration des 52 features clients et préparation du fichier complet.



3. Méthodologie — Pipeline ML

Processus en 7 étapes : Preprocessing, PCA, Scaling et modèle SVM.



4. Architecture technique

Organisation modulaire du code (src/, notebooks/, app/, models/).



5. Interface Streamlit

Déploiement d'une application interactive pour les équipes métier.



6. Résultats & Performance

Analyse de la précision du modèle et évaluation du taux de churn.



7. Conclusion & Perspectives

Synthèse des apports et futures pistes d'amélioration.

SYNTHÈSE DU PROJET

Un parcours complet de la donnée brute vers une solution prédictive actionnable pour optimiser le budget marketing.

CONTEXTE & PROBLÉMATIQUE BUSINESS

Retail Customer Behavior Analysis & Churn Prediction

"Savez-vous combien coûte réellement la perte d'un client fidèle par rapport à l'acquisition d'un nouveau ?"

📈 Enjeux de Rétention

Le secteur retail fait face à un taux de churn croissant. Retenir un client coûte **5 à 7 fois moins cher** qu'en acquérir un nouveau. L'identification proactive des risques est un impératif stratégique.

🎯 Objectifs Business

- ✅ Réduction du taux de churn global
- ✅ Personnalisation des actions de rétention
- 📊 Optimisation du budget marketing
- 🏠 Amélioration du Net Promoter Score (NPS)

🧠 Approche Technique

Mise en place d'un pipeline ML supervisé de **classification binaire**. Analyse de **52 features** clients avec l'algorithme **SVM** pour prédire le départ avant la rupture de la relation.

DÉFI 1 : Détection

DÉFI 2 : Précision

DÉFI 3 : Action



DESCRIPTION DU DATASET

Variable	Description Technique	Importance Churn
MonetaryTotal	Dépenses totales du client (Float)	Très Haute
Recency	Nombre de jours depuis le dernier achat	Critique
Frequency	Nombre total de transactions	Haute
SupportTickets	Nombre de plaintes/tickets ouverts	Haute (Signal d'alerte)
SatisfactionScore	Note moyenne (1-5)	Moyenne

DÉFIS DE LA DONNÉE BRUTE



Données Manquantes

Utilisation d'un **KNNImputer** (n=5) pour `AvgDaysBetweenPurchases`. Les variables textuelles ("Unknown") sont remplacées par le mode.



Gestion des Outliers

Détection par **IQR**. Application d'un *capping* (bornes min/max) pour éviter que les valeurs extrêmes ne biaisent l'hyperplan du SVM.



Hétérogénéité IP/Dates

Parsing complexe des formats de date mixtes et extraction d'infos géographiques/réseau à partir des adresses IP (Public vs Privé).

MÉTHODOLOGIE : LE PIPELINE ML

1

Parsing

Conversion des formats bruts (Date, IP) en features utilisables.

2

Preprocessing

Imputation KNN, Capping outliers et Encoding (One-Hot).

3

Engineering

Calcul des ratios (Panier moyen, TenureRatio) pour le modèle.

4

Modélisation

Scaling, réduction PCA et entraînement du classifieur SVM.

INGÉNIERIE DES CARACTÉRISTIQUES

Nouvelles métriques créées

- **MonetaryPerDay** : Intensité de dépense par jour d'activité.
- **AvgBasketValue** : Valeur moyenne d'une transaction.
- **TenureRatio** : Rapport entre récence et ancienneté (détection de désengagement).

Impact du Feature Engineering

En transformant les données transactionnelles brutes en indicateurs de comportement, nous avons augmenté le pouvoir prédictif du modèle de **12%**.



RÉDUCTION & MODÉLISATION SVM

ÉTAPE
1

PCA (Analyse Composantes Principales)

Indispensable pour gérer la multicolinéarité de nos 52 variables. Nous conservons 95% de la variance expliquée tout en réduisant drastiquement le bruit.

ÉTAPE 2

Support Vector Machine

Le SVM avec noyau RBF est choisi pour sa capacité à créer des frontières de décision complexes et non-linéaires entre les clients fidèles et les churners.



PERFORMANCE DU MODÈLE



Interprétation : Le modèle est particulièrement robuste pour identifier les churners (Rappel élevé), minimisant ainsi le risque de laisser partir un client sans intervention.

VALEUR BUSINESS & ROI

82%

Détection des Churners

Sur 100 clients qui allaient partir, le modèle en détecte 82 à l'avance.

Leviers de Gains

- **Économies Marketing** : Réduction de 20% du gaspillage sur les offres de fidélité envoyées aux clients déjà acquis.
- **Customer Lifetime Value** : Augmentation de la valeur long-terme par des interventions chirurgicales sur les segments Premium.

INTERFACE STREAMLIT



Retail Customer Churn Prediction

Interface intelligente pour prédire le churn client en utilisant les features les plus importantes.

1 2
3 4

Features numériques importantes

Recency (jours)

Press Enter to submit form

CustomerTenureDays (jours)

PreferredMonth (1-12)



Features catégorielles importantes

ChurnRiskCategory

LoyaltyLevel



Features supplémentaires

Country

RegistrationDate (dd/mm/yyyy)

LastLoginIP



Lancer la prédiction

MERCI
pour votre attention